


TEMA 3: MODELOS DE DATOS FUSIONADOS Y MODELOS ESTÁTICOS PARA DATOS DE PANEL



M. Camacho

con la colaboración de A. Beyaert, M. González, A. Quesada
Departamento de Métodos Cuantitativos para la Economía y la Empresa

UNIVERSIDAD DE
MURCIA

1. Introducción

2. Datos fusionados

- 2.1 Descripción de los datos
- 2.2 El modelo de regresión
- 2.3 Estimación


3. Datos de panel

- 3.1 Descripción de los datos
- 3.2 El modelo de regresión
- 3.3 El control de la heterogeneidad inobservable constante
- 3.4 El modelo de efectos fijos
- 3.5 El modelo de efectos aleatorios
- 3.6. Contraste de Hausman de especificación del modelo

Bibliografía básica:

Wooldridge, J. 2007. *Introducción a la econometría: un enfoque moderno*. Ed. Thomson, cap.13 y 14

- ❑ Hasta ahora, análisis de regresión con:
 - Datos de corte transversal
 - Datos de serie temporal
- ❑ En este tema, análisis de regresión con datos que combinan información de corte transversal y de serie temporal:
 - Datos fusionados de secciones cruzadas independientes
 - Datos de panel o longitudinales estáticos



Datos fusionados: estudio de efectos temporales

- Modelo de Fertilidad de las mujeres

$$y_i = \beta_0 + \delta_0 F74_i + \delta_1 F76_i + \delta_2 F78_i + \delta_3 F78_i + \delta_4 F80_i + \delta_5 F82_i + \delta_6 F84_i + \alpha' X_i + \varepsilon_i,$$

i = 1, …, 1129 t = 1972, 1974, 1976, 1978, 1980, 1982, 1984

N* = 1129 observaciones

y: número total de niños que ha tenido una mujer

F74, …, F84: variables ficticias temporales

X: vector de variables explicativas que incluye factores observados que afectan a la fertilidad (educación, edad, raza, región, entorno)

- Permite contestar a: una vez descontado el efecto de otros factores observables, ¿han cambiado los índices de fertilidad en el tiempo?

Nota: también se pueden incluir términos de interacción entre las ficticias anuales y alguna de las explicativas

Datos de panel

- Modelo de crecimiento de Solow

$$y_{it} = \beta_0 + \beta_1 x_{1,it} + \beta_2 x_{2,it} + \beta_3 x_{3,it} + \eta_i + \varepsilon_{it}, \quad i = 1, \dots, 86 \quad t = 60's, 70's, 80's$$

y_{it} : tasa de crecimiento de la renta del país i en la década t

x_1 : log. renta inicial per cápita (β_1 : tasa de convergencia)

x_2 : tasa de crecimiento de la población

x_3 : porcentaje del PIB destinado a inversión

η_i : características inobservables propias del país i , probablemente correlacionadas con su renta inicial, su inversión y su población

Ventajas respecto de sección cruzada:

- **Tamaño muestral** más elevado (estimación más precisa)
- Permite **estudiar efectos temporales**: cambios en el tiempo del término constante o de los efectos de alguna de las explicativas
 - Disminución de la tasa de fertilidad en España
 - Mejora la nota de los universitarios en cursos más elevados
- Permite realizar **estudio de acontecimientos**: efectos causales de un determinado suceso o medida de política económica
 - Carnet por puntos => reducción de accidentes
 - Subida salario mínimo => aumento del desempleo
 - Programas de formación de trabajadores => mejora de la productividad
 - Apertura de discoteca => precio de vivienda (medición de efectos externos)
 - Estudios universitarios => mejoran el salario

2. Datos fusionados

2.1 Descripción de los datos

- **Datos fusionados:** se obtienen realizando muestreo aleatorio de una población en diferentes momentos del tiempo
- En t se dispone de N_t observaciones de una población, donde $t=1,2,\dots,T$ y $T \geq 2$

$$y_i \quad i=1,\dots,N^*$$

el número total de observaciones es $N^* = N_1 + N_2 + \dots + N_T$

Si $T=2$, el vector de observaciones es:

$$\left[\underbrace{y_1 \quad y_2 \quad \dots \quad y_{N_1}}_{t=1} \quad \underbrace{y_{N_1+1} \quad y_{N_1+2} \quad \dots \quad y_{N_1+N_2}}_{t=2} \right] \Rightarrow N^* = N_1 + N_2$$

- Provienen de observaciones muestrales independientes

2. Datos fusionados

2.2 El modelo de regresión

$$y_i = \beta_0 + \delta_0 F2_i + \dots + \delta_{T-2} FT_i + \beta_1 x_{1i} + \dots + \beta_k x_{ki} + \varepsilon_i, \quad i = 1, \dots, N \quad i \in \{t=1, \dots, t=T\}$$

- $F2_i, \dots, FT_i$ son ($T-1$) ficticias aditivas temporales (podrían haber multiplicativas)
- En notación matricial $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$

$$\begin{bmatrix} y_1 \\ \vdots \\ y_{N_1} \\ \vdots \\ y_{N^*-N_T+1} \\ \vdots \\ y_{N^*} \end{bmatrix} = \frac{\begin{bmatrix} 1 & F2_1 & \cdots & FT_1 & x_{11} & \cdots & x_{k1} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 1 & F2_{N_1} & \cdots & FT_{N_1} & x_{1N_1} & \cdots & x_{kN_1} \\ \vdots & \vdots & & \vdots & \vdots & & \vdots \\ 1 & F2_{N^*-N_T+1} & \cdots & FT_{N^*-N_T+1} & x_{1(N^*-N_T+1)} & \cdots & x_{k(N^*-N_T+1)} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 1 & F2_{N^*} & \cdots & FT_{N^*} & x_{1N^*} & \cdots & x_{kN^*} \end{bmatrix}}{\begin{bmatrix} \beta_0 \\ \delta_0 \\ \vdots \\ \delta_{T-2} \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix}} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_{N_1} \\ \vdots \\ \varepsilon_{N^*-N_T+1} \\ \vdots \\ \varepsilon_{N^*} \end{bmatrix}$$


- En notación semimatrarial

$$y_i = X'_i \boldsymbol{\beta} + \varepsilon_i \quad \forall i=1, \dots, N \text{ donde } X'_i = (1 \quad F2_i \quad \dots \quad FT_i \quad x_i \quad \dots \quad x_i)$$

□ El modelo de datos fusionados

$$y_i = X'_i \beta + \varepsilon_i \quad i = 1, \dots, N_1, N_1 + 1, \dots, N_1 + N_2, \dots, N^*$$

- Si el modelo cumple los supuestos de Gauss-Markov:
 - MCO es ELIO
 - Son válidos los procedimientos de inferencia habituales
- Si hay heteroscedasticidad la tratamos como en sección cruzada



2. Datos fusionados

2.4 Utilidad de estos modelos

Normalmente el modelo

$$y_i = X'_i \beta + \varepsilon_i \quad \forall i=1, \dots, N \text{ donde } X'_i = (1 \quad F_{2i} \quad \dots \quad F_{Ti} \quad x_i \quad \dots \quad x_i)$$

incluye ficticias temporales para:

- Ficticias aditivas: La fertilidad empeora con el tiempo
- Ficticias multiplicativas: fertilidad empeora a través de una explicativa como puede ser la renta
- Estudios de acontecimiento: análisis de causalidad (ejemplo siguiente)

2. Datos fusionados

2.4 Utilidad de estos modelos

Estudio de acontecimiento

Efecto causal

1. Si toda las observaciones fueran iguales y reaccionaran igual

- $T=1$ cuando ocurre el acontecimiento y $T=0$ cuando no ocurre

$$y = \beta_0 + \beta_1 T \Rightarrow EC = (y / T = 1) - (y / T = 0) = \beta_1$$

- **Problema:** las observaciones nunca son iguales

2. Solución: muestreos en experimentos

- Experimentos aleatorios: aleatoriamente se asigna

- Grupo Tratamiento ($T=1$)


- Grupo de Control ($T=0$)

$$y_i = \beta_0 + \beta_1 T_i + \varepsilon_i$$

- Estimador en diferencias: Efecto causal medio

$$ECM = E(y / T = 1) - E(y / T = 0) = \bar{y}^T - \bar{y}^C = \beta_1$$

- **Problema:** Son costosos y no siempre viables



$$\bar{y}^C = E(y / control) = \beta_0$$

$$\bar{y}^T = E(y / tratamiento) = \beta_0 + \beta_1$$

$$\bar{y}^T = \beta_0 + \beta_1$$

$$y^C = \beta_0$$

2. Datos fusionados

2.4 Utilidad de estos modelos

Estudio de acontecimiento

3. Solución: experimento natural o cuasi experimento

- Acontecimiento (incinerador) genera GT y GC **como si** hubiese sido un experimento aleatorio
- **Problema:** parte de $\bar{y}^T - \bar{y}^C = \beta_1$ ya estaba antes del acontecimiento (no es aleatorio)
- **Solución:** estimador de la **diferencia en las diferencias** con **datos fusionados**
- Ejemplo: Efecto causal de un incinerador sobre el precio de la vivienda

$$y_i = \beta_0 + \delta_0 F81_i + \beta_1 cerca_i + \delta_1 F81_i \cdot cerca_i + \alpha' X_i + \varepsilon_i,$$
$$i=1, \dots, 321 \quad t = 1978, 1981 \quad N_{1978} = 179 \quad N_{1981} = 142$$

y: precio de la vivienda en términos reales

F81: variable ficticia temporal que toma valor 1 si t=1981

T = cerca: ficticia que toma valor uno si la casa está cerca del incinerador

X: variables explicativas de las características observables de las viviendas (años, superficie, nº habitaciones....)

- δ_1 es el coeficiente que interesa. Indica el efecto causal del incinerador en la caída del precio de la vivienda. Su valor estimado se obtendrá usando el **estimador de la diferencia en las diferencias**

Datos fusionados: estudio de acontecimientos

- δ_1 y el **estimador de la diferencia en las diferencias**

➤ Sin perder generalidad, supongamos $X_i=0$

$$y_i = \beta_0 + \delta_0 F81_i + \beta_1 cerca_i + \delta_1 F81_i \cdot cerca_i + \varepsilon_i$$



➤ Llamemos

$$\bar{y}_0^C = E(y / control)_{78} = \beta_0$$

$$\bar{y}_0^T = E(y / tratamiento)_{78} = \beta_0 + \beta_1$$

$$\bar{y}_1^C = E(y / control)_{81} = \beta_0 + \delta_0$$

$$\bar{y}_1^T = E(y / tratamiento)_{81} = \beta_0 + \delta_0 + \beta_1 + \delta_1$$



2. Datos fusionados

2.4 Utilidad de estos modelos

- Tres formas de encontrar δ_1

$$y_i = \beta_0 + \delta_0 F81_i + \beta_1 cerca_i + \delta_1 F81_i \cdot cerca_i + \varepsilon_i$$


	control	tratamiento	
78	$\bar{y}_0^C = \beta_0$	$\bar{y}_0^T = \beta_0 + \beta_1$	$\rightarrow \bar{y}_0^T - \bar{y}_0^C = \beta_1$
81	$\bar{y}_1^C = \beta_0 + \delta_0$	$\bar{y}_1^T = \beta_0 + \delta_0 + \beta_1 + \delta_1$	$\rightarrow \bar{y}_1^T - \bar{y}_1^C = \beta_1 + \delta_1$

\downarrow \downarrow
 $\bar{y}_1^C - \bar{y}_0^C = \delta_0$ $\bar{y}_1^T - \bar{y}_0^T = \delta_0 + \delta_1$
2 $(\bar{y}_1^T - \bar{y}_0^T) - (\bar{y}_1^C - \bar{y}_0^C) = \delta_1$ 1
3 $\bar{y}_1^T - [\underbrace{\bar{y}_0^T + (\bar{y}_1^C - \bar{y}_0^C)}_{\bar{y}^{cf}}] = (\beta_0 + \delta_0 + \beta_1 + \delta_1) - [\beta_0 + \beta_1 + (\beta_0 + \delta_0 - \beta_0)] = \delta_1$

2. Datos fusionados

2.4 Utilidad de estos modelos

- Gráficamente



2. Datos fusionados

2.4 Utilidad de estos modelos

$$y_i = \beta_0 + \delta_0 F81_i + \beta_1 cerca_i + \delta_1 F81_i \cdot cerca_i + \varepsilon_i$$

- El supuesto de tendencias paralelas

- En los cálculos anteriores hemos supuesto
 - La diferencia entre T y C, medida por β_1 , se mantiene en el tiempo \Rightarrow aceptable
 - El incremento temporal, medido por δ_0 , afecta igual a T y C \Rightarrow dudoso
- Genera inconsistencia
 - Supongamos
 - Incremento temporal de C es δ_0
 - Incremento temporal de T es $\delta_0 + \Delta$
 - En este caso el dif-dif queda

$$(\bar{y}_1^T - \bar{y}_0^T) - (\bar{y}_1^C - \bar{y}_0^C) = (\delta_0 + \Delta + \delta_1) - \delta_0 = \delta_1 + \Delta$$

- Econométricamente ocurre cuando

$$\text{cov}(\varepsilon_i, F81_i cerca_i) \neq 0$$

3. Datos de panel

3.1 Descripción de los datos

- **Datos de panel** (o longitudinales): observaciones repetidas en el tiempo para una muestra de sección cruzada (individuos, familias, empresas, regiones, países, etc.)
- Son las **mismas unidades de sección cruzada** las que son observadas a través del tiempo

y_{it} ; $i=1,\dots,N$ $t=1,\dots,T \Rightarrow$ el número total de observaciones es NT

Si $T=2$, el vector de observaciones es:


$$\left[\underbrace{y_{11} \quad y_{21} \quad \cdots \quad y_{1N}}_{t=1} \quad \underbrace{y_{12} \quad y_{22} \quad \cdots \quad y_{2N}}_{t=2} \right] \Rightarrow NT = 2N$$

- Las observaciones no se distribuyen de forma independiente a lo largo del tiempo

3. Datos de panel

3.1 Descripción de los datos

- Resulta útil visualizar los datos de la siguiente manera:



3. Datos de panel

3.1 Descripción de los datos

□ Dimensiones del panel de datos

- N grande y T pequeño: *micropaneles* o *paneles cortos*

“Datos micro” observados en distintos momentos del tiempo (ej. datos de encuestas familiares o del balance de las empresas):

- PSID (Panel Study of Income Dynamics)
- ECHP (European Community Household Income and Wealth)
- EPA (Encuesta de Población Activa)
- ESEE (Encuesta sobre Estrategias Empresariales)
- ECPF (Encuesta Continua de Presupuestos Familiares)

- N pequeño y T grande: *paneles largos*

“Datos macro” observados a lo largo del tiempo (ej. bases de datos internacionales):

- Estadísticas de la OCDE, Eurostat, FMI, etc.
- Penn World Table

3. Datos de panel

3.1 Descripción de los datos

□ Los paneles de datos pueden ser:

- Completos o equilibrados: $T_i = T \quad \forall i$

No falta ninguna observación temporal para ninguna unidad de sección cruzada

- Incompletos: $T_i \neq T$ para algún i

Falta alguna observación temporal para alguna unidad

□ En este tema consideramos:

- Modelos lineales y sin endógena retardada
- Paneles completos
- “Datos micro”: N grande y T pequeño

➡ Para las aproximaciones asintóticas suponemos T fijo y $N \rightarrow \infty$

3.2 El modelo de regresión

- Hay una única ecuación para las N unidades de sección cruzada

$$y_{it} = \beta_0 + \delta_0 F2_t + \dots + \delta_{T-2} FT_t + \beta_1 x_{1,it} + \dots + \beta_k x_{k,it} + \eta_i + \varepsilon_{it}, \\ i = 1, \dots, N \quad t = 1, \dots, T$$

- $F2_t, \dots, FT_t$: son $(T-1)$ variables ficticias aditivas temporales (también podría haber multiplicativas)
- η_i es el “efecto individual” o “efecto inobservable” o “efecto permanente”: refleja diferencias inobservables constantes en el tiempo entre las unidades de sección cruzada

3. Datos de panel

3.2 El modelo de regresión

- Normalmente los datos se organizan mediante unidades de sección cruzada

$$\begin{bmatrix} y_{11} \\ \vdots \\ y_{1T} \\ \vdots \\ y_{N1} \\ \vdots \\ y_{NT} \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & F2_1 & \dots & FT_1 x_{1,11} & x_{2,11} & \cdots & x_{k,11} \\ \vdots & \ddots & & \vdots & \ddots & & \vdots \\ 1 & F2_T & \dots & FT_T x_{1,1T} & x_{2,1T} & \cdots & x_{k,1T} \\ \vdots & & & \vdots & \ddots & & \vdots \\ 1 & F2_1 & \dots & FT_1 x_{1,N1} & x_{2,N1} & \cdots & x_{k,N1} \\ \vdots & & & \vdots & \ddots & & \vdots \\ 1 & F2_T & \dots & FT_T x_{1,NT} & x_{2,NT} & \cdots & x_{k,NT} \end{bmatrix}}_Y \cdot \underbrace{\begin{bmatrix} \beta_0 \\ \delta_0 \\ \vdots \\ \delta_{T-2} \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix}}_\beta + \underbrace{\begin{bmatrix} \eta_1 \\ \vdots \\ \eta_1 \\ \vdots \\ \eta_N \\ \vdots \\ \eta_N \end{bmatrix}}_\eta + \underbrace{\begin{bmatrix} \varepsilon_{11} \\ \vdots \\ \varepsilon_{1T} \\ \vdots \\ \varepsilon_{N1} \\ \vdots \\ \varepsilon_{NT} \end{bmatrix}}_\varepsilon$$

⇒ notación matricial: $Y = X\beta + \eta + \varepsilon$

⇒ notación semimatrarial: $y_{it} = X'_{it}\beta + \eta_i + \varepsilon_{it}$ $i=1,\dots,N$ $t=1,\dots,T$

donde $X'_{it} = (1 \quad F2_t \quad \dots \quad FT_t x_{1,it} \quad \cdots \quad x_{k,it})$

Características adicionales de datos de panel:

- Permite modelizar **respuestas dinámicas** en las poblaciones de sección cruzada (introduciendo variables retardadas).
- Permite controlar las diferencias **inobservables** entre las unidades de sección cruzada.


3. Datos de panel

3.3 El control de la heterogeneidad inobservable constante

- Tenemos el siguiente modelo con **efectos individuales**

$$y_{it} = X'_{it}\beta + \eta_i + \varepsilon_{it} \quad i=1, \dots, N \quad t=1, \dots, T$$

- **Objetivo:** estimar β para cuantificar las relaciones causales entre las variables
- Problema: η_i no se observa
→ omisión de variables relevantes



3. Datos de panel

3.3 El control de la heterogeneidad inobservable constante

$$y_{it} = X'_{it}\beta + \eta_i + \varepsilon_{it} \quad i=1,\dots,N \quad t=1,\dots,T$$

- Si $\text{Corr}(X_{it}, \eta_i) = 0$ la estimación MCO es consistente pero no óptima

Con datos de panel la estimación más adecuada es **el estimador de efectos aleatorios** \Rightarrow Modelo de efectos aleatorios

- Si $\text{Corr}(X_{it}, \eta_i) \neq 0$ la estimación MCO no es consistente

Con datos de panel la estimación más adecuada es **el estimador de efectos fijos** \Rightarrow Modelo de efectos fijos

Datos de panel: el control de la heterogeneidad inobservable constante

- Modelo de crecimiento de Solow

$$y_{it} = \beta_0 + \beta_1 x_{1,it} + \beta_2 x_{2,it} + \beta_3 x_{3,it} + \eta_i + \varepsilon_{it}, \quad i = 1, \dots, 86 \quad t = 60's, 70's, 80's$$

y_{it} : tasa de crecimiento de la renta del país i en la década t

x_1 : log. renta inicial per cápita (β_1 : tasa de convergencia)

x_2 : tasa de crecimiento de la población

x_3 : porcentaje del PIB destinado a inversión

η_i : características inobservables propias del país i , probablemente correlacionadas con su renta inicial, su inversión y su población

⇒ La estimación MCO (y sobre x_1 , x_2 y x_3) será sesgada e inconsistente

- Incluso cuando no hay datos sobre η_i , los datos de panel permiten la estimación consistente de β_1 , β_2 y β_3

3.4 El modelo de efectos fijos

$$y_{it} = X'_{it}\beta + \underbrace{\eta_i + \varepsilon_{it}}_{u_{it}} \quad i=1, \dots, N \quad t=1, \dots, T$$

- Supuestos, además de $\text{Corr}(X_{it}, \eta_i) \neq 0$
 - S.1. Variables explicativas estrictamente exógenas: en todos los períodos, el término de error ε_{it} está incorrelacionado con los valores presentes pasados y futuros de las explicativas
$$E(\varepsilon_{it}|X) = 0, \quad \forall t$$

➡ Excluye modelos con variables endógenas retardadas
 - S.2. Perturbaciones clásicas: Los errores son condicionalmente homocedásticos y no serialmente correlacionados

$$V(\varepsilon_i|X) = \sigma^2 I_T \quad \text{con } \varepsilon_i = (\varepsilon_{i1}, \dots, \varepsilon_{iT})'$$

3. Datos de panel

3.4 El modelo de efectos fijos

El estimador de efectos fijos $y_{it} = X'_{it}\beta + \underbrace{\eta_i + \varepsilon_{it}}_{u_{it}}$

- Resulta de restar a cada observación su media individual
- Se obtiene:
 - 1º Calculando la ecuación para la media de cada grupo

$$\bar{y}_i = \bar{X}'_i \beta + \eta_i + \bar{\varepsilon}_i, \quad i = 1, \dots, N \quad \text{con} \quad \bar{\varepsilon}_i = \frac{\sum_{t=1}^T \varepsilon_{it}}{T}$$

- 2º Restando a la ecuación original la ecuación de la media

$$y_{it} - \bar{y}_i = (X_{it} - \bar{X}_i)' \beta + \varepsilon_{it} - \bar{\varepsilon}_i, \quad i = 1, \dots, N \quad t = 1, \dots, T$$

- El modelo en desviaciones de la media:

$$\tilde{y}_{it} = \tilde{X}'_{it} \beta + \tilde{\varepsilon}_{it}, \quad i = 1, \dots, N \quad t = 1, \dots, T$$

$$\tilde{y}_{it} = (y_{it} - \bar{y}_i) \quad \tilde{X}_{it} = (X_{it} - \bar{X}_i) \quad \tilde{\varepsilon}_{it} = (\varepsilon_{it} - \bar{\varepsilon}_i)$$


El estimador del modelo en desviaciones de la media

- El estimador MCO del modelo en desviaciones de la media es el **estimador de efectos fijos** o **estimador intra-grupos**

$$\hat{\beta}_{EF} = (\tilde{X}'\tilde{X})^{-1}\tilde{X}'Y$$

- Se denomina también estimador intra-grupos porque sólo utiliza la variación temporal dentro de cada sección cruzada
- Bajo S.1 y S.2, $\hat{\beta}_{EF}$ es **insesgado y óptimo**. También es consistente cuando $N \rightarrow \infty$.

- Podemos obtener el efecto inobservable: $\hat{\eta}_i = \bar{y}_i - \bar{X}'\hat{\beta}_{EF}$, $i = 1, \dots, N$, pero esta estimación no es consistente cuando $N \rightarrow \infty$, para T fijo.
- Si alguno de los regresores es constante en el tiempo, no se podrá distinguir su efecto del de η_i



Limitación del modelo de efectos fijos

- El modelo de efectos fijos deja parte de la regresión sin modelizar (la que sólo tiene variación de sección cruzada). Si esta parte explica mucha variabilidad de la variable dependiente, el modelo estimado tendrá muy poca capacidad predictiva
- La posibilidad de controlar la heterogeneidad inobservable solo es una ventaja cuando el objetivo del análisis econométrico es la medición de relaciones estructurales, no la predicción.
- El coste del modelo de efectos fijos es que excluimos los efectos de cualquier variable observada constante en el tiempo.

3.5 El modelo de efectos aleatorios

$$y_{it} = X'_{it}\beta + \eta_i + \varepsilon_{it}, \quad i = 1, \dots, N \quad t = 1, \dots, T$$

- En el modelo de efectos aleatorios η_i es una variable aleatoria inobservable **no correlacionada** con las variables explicativas de modelo, $\text{Corr}(X_{it}, \eta_i) = 0$, $t = 1, 2, \dots, T$:

$$y_{it} = X'_{it}\beta + \underbrace{\eta_i + \varepsilon_{it}}_{u_{it}}, \quad i = 1, \dots, N \quad t = 1, \dots, T$$

$$y_{it} = X'_{it}\beta + u_{it}, \quad i = 1, \dots, N \quad t = 1, \dots, T$$

- Ahora el error del modelo es un **término de error compuesto no correlacionado** con las variables explicativas del modelo

3.5 El modelo de efectos aleatorios

$$y_{it} = X'_{it}\beta + u_{it}, \quad i = 1, \dots, N \quad t = 1, \dots, T$$

$$u_{it} = \eta_i + \varepsilon_{it}, \quad \text{Corr}(X_{it}, \eta_i) = 0$$

- Bajo los supuestos:

$$\begin{cases} S.1'. \quad \eta_i | X_i \sim \text{iid}(0, \sigma_\eta^2) \\ S.2'. \quad \varepsilon_{it} | X_i \sim \text{iid}(0, \sigma^2) \\ S.3'. \quad \eta_i \text{ y } \varepsilon_{it} \text{ son independientes} \end{cases}$$

- El modelo de efectos aleatorios presenta:

➤ Exogeneidad estricta: $E(u_{it} | X) = 0, \quad \forall t$

➤ Autocorrelación:

$$E(u_{it} u_{is}) = \begin{cases} \sigma^2 + \sigma_\eta^2, & t = s \\ \sigma_\eta^2, & t \neq s \end{cases}$$

➡ El estimador MCO es insesgado y consistente, pero no óptimo

3.5 El modelo de efectos aleatorios

La autocorrelación en el modelo de efectos aleatorios


- La matriz de covarianzas de los T valores correspondientes al individuo i -ésimo es:

$$V(u_i)_{T \times T} = E(u_i u_i') = V \begin{bmatrix} u_{i1} \\ u_{i2} \\ \vdots \\ u_{iT} \end{bmatrix} = \begin{bmatrix} (\sigma_\eta^2 + \sigma^2) & \sigma_\eta^2 & \dots & \sigma_\eta^2 \\ \sigma_\eta^2 & (\sigma_\eta^2 + \sigma^2) & \dots & \vdots \\ \vdots & \vdots & \ddots & \sigma_\eta^2 \\ \sigma_\eta^2 & \dots & \sigma_\eta^2 & (\sigma_\eta^2 + \sigma^2) \end{bmatrix} = v$$

- ➡ La correlación entre dos observaciones provenientes de un mismo individuo es constante y no desaparece en el tiempo

- La matriz de covarianzas para toda la muestra es diagonal por bloques:

$$V(u)_{TN \times TN} = E(uu') = \begin{bmatrix} v_{T \times T} & 0 & \cdots & 0 \\ 0 & v_{T \times T} & & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & v_{T \times T} \end{bmatrix} = V$$

- La matriz de covarianzas no es una matriz diagonal
 para buscar optimalidad hay que estimar por MCG



3. Datos de panel

3.5 El modelo de efectos aleatorios

- El estimador óptimo del modelo de efectos aleatorios sería el estimador MCG:

$$\hat{\beta}_{\text{MCG}} = (\mathbf{X}' \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}' \mathbf{V}^{-1} \mathbf{Y}$$

pero \mathbf{V} depende de σ^2 y σ_η^2 que son desconocidos

➡ hay que hallar el estimador **MCG factible**

- MCG factible es el **estimador de efectos aleatorios**

$$\hat{\beta}_{\text{EA}} = (\mathbf{X}' \hat{\mathbf{V}}^{-1} \mathbf{X})^{-1} \mathbf{X}' \hat{\mathbf{V}}^{-1} \mathbf{Y}$$



3. Datos de panel

3.5 El modelo de efectos aleatorios

- Para calcular \hat{V} necesitamos estimaciones consistentes de σ^2 y σ_η^2 :

$$\hat{\sigma}^2 = \frac{1}{N(T-1)-k} \sum_{i=1}^N \sum_{t=1}^T \left(\tilde{y}_{it} - \tilde{X}'_{it} \hat{\beta}_{EF} \right)^2$$

$$\hat{\sigma}_\eta^2 = \frac{1}{N} \sum_{i=1}^N \left(\bar{y}_i - \bar{X}_i \hat{\beta}_{EG} \right)^2 - \frac{\hat{\sigma}^2}{T}$$


donde $\hat{\beta}_{EG}$ es el “estimador entre-grupos” resultante de la estimación MCO de:

$$\bar{y}_i = \bar{X}'_i \beta + \eta_i + \bar{\varepsilon}_i, \quad i = 1, \dots, N$$

$$\hat{\beta}_{EG} = (\bar{X}' \bar{X})^{-1} \bar{X}' \bar{Y}$$

Conclusión

- Bajo el supuesto de efectos individuales incorrelacionados con las explicativas, el **estimador de efectos aleatorios** es **consistente y asintóticamente óptimo**.
- Ojo!! sería inconsistente si los efectos individuales están correlacionados con las explicativas.



3. Datos de panel

3.6 El contraste de Hausman

Recordemos:

- $\hat{\beta}_{EA}$ es:
 - consistente y asintóticamente óptimo si $\text{Corr}(X_{it}, \eta_i) = 0$
 - inconsistente si $\text{Corr}(X_{it}, \eta_i) \neq 0$
 - $\hat{\beta}_{EF}$ es siempre consistente
- ➡ Si $\text{Corr}(X_{it}, \eta_i) = 0$ ambas estimaciones serían muy similares
- Necesitamos elegir entre $\hat{\beta}_{EA}$ y $\hat{\beta}_{EF}$



3. Datos de panel

3.6 El contraste de Hausman

- El contraste de Hausman (1978) contrasta la correlación entre los efectos individuales y las explicativas comparando $\hat{\beta}_{EF}$ y $\hat{\beta}_{EA}$

$H_0 : \eta_i$ y X_i no correlacionados ($\hat{\beta}_{EF} \approx \hat{\beta}_{EA}$)

$H_A : \eta_i$ y X_i correlacionados

- El estadístico para el contraste es:

$$H = (\hat{\beta}_{EA} - \hat{\beta}_{EF})' \left(\hat{V}(\hat{\beta}_{EF}) - \hat{V}(\hat{\beta}_{EA}) \right)^{-1} (\hat{\beta}_{EA} - \hat{\beta}_{EF})_{H_0}^a \chi_k^2$$

donde k es el número de parámetros del modelo

Lo que hemos aprendido:

- Qué son datos fusionados y qué son datos de panel
- Estimación con datos fusionados: bajo los supuestos clásicos MCO es ELIO
- Estimación con datos de panel:
 - Si el efecto individual está correlacionado con las explicativas:
 - MCO sesgado e inconsistente
 - El estimador de efectos fijos es insesgado y óptimo
 - Si el efecto individual no está correlacionado con las explicativas:
 - MCO insesgado pero no óptimo
 - El estimador de efectos aleatorios es insesgado y asintóticamente óptimo
 - Contraste de Hausman para elegir entre el estimador de efectos fijos y el estimador de efectos aleatorios